

RELATÓRIO DE DIAGNÓSTICO ESTATÍSTICO

FIAP – Bacharelado em Ciência da Computação (Turma 1CCJ)

Elaborado por:

- [Maria Eduarda Rocha Benjamim] - RM: [570554]
- [Pedro Henrique Neves] - RM: [571382]
- [Akin Alexandre Mendes Martins] - RM: [572773]

Componente Curricular: Modelagem Linear para Aprendizagem de Máquina

Data de Emissão: Junho de 2026

1. SUMÁRIO EXECUTIVO

Este relatório consolida uma análise estatística exploratória do histórico global de lançamentos aeroespaciais com base no conjunto de dados `Space_Corrected.csv`. O objetivo central é fornecer subsídios quantitativos para avaliação de risco, previsibilidade operacional e identificação de faixas de custo predominantes na Nova Economia Espacial.

Foram analisadas duas variáveis: Ano de Lançamento (quantitativa discreta) e Custo da Missão (USD milhões) (quantitativa contínua). As evidências estatísticas indicam crescimento da atividade espacial nas décadas recentes e forte concentração de missões em faixas de custo inferiores a USD 100 milhões, com distribuição assimétrica à direita e presença de poucos projetos de investimento excepcionalmente elevados.

2. METODOLOGIA E ESCOPO DOS DADOS

A base de dados foi carregada diretamente do arquivo `Space_Corrected.csv` no ambiente Google Colab, utilizando Pandas, NumPy, Matplotlib e Seaborn para processamento e visualização.

Procedimentos executados no notebook

1. Conversão da coluna `Rocket` para numérico, removendo separadores e criando a variável `Custo_Milhoes`.
2. Extração do ano a partir da coluna `Datum` com `pd.to_datetime(...).dt.year`.
3. Remoção de registros sem ano válido (`dropna(subset=['Ano'])`).
4. Separação das variáveis em dois conjuntos analíticos: `Ano` e `Custo_Milhoes`.
5. Construção de tabelas de distribuição de frequências e cálculo de estatísticas descritivas.
6. Geração de visualizações: gráfico temporal de lançamentos por ano e histograma com curva KDE para os custos.

Importante: o notebook fornecido não executa uma amostragem aleatória de $n=100$ observações. As tabelas e estatísticas derivadas correspondem aos registros válidos presentes no arquivo após a limpeza dos dados. Se o trabalho exigir estritamente $n=100$, será necessário inserir uma etapa explícita de amostragem aleatória no código (por exemplo, `data1.sample(n=100, random_state=42)`).

3. TABELAS DE DISTRIBUIÇÃO DE FREQUÊNCIAS (TDF)

3.1 Variável Quantitativa Discreta: Ano de Lançamento

A tabela foi construída com `value_counts().sort_index()` sobre a variável Ano. A frequência relativa foi calculada por

$$f_i / \sum f_i \times 100$$

Ano de Lançamento	fi	Fi (acumulada)	fr%
1957	(gerado pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
1958	(gerado pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
...	...	...	...
2020	(gerado pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
Total	Σf_i	—	100%

Tabela 1 – Distribuição de frequências do ano de lançamento (resultado direto do notebook).

A interpretação operacional é a mesma observada no notebook: há predominância de registros nas décadas mais recentes, evidenciando intensificação da atividade espacial ao longo do tempo.

3.2 Variável Quantitativa Contínua: Custo da Missão (USD Milhões)

As classes foram definidas automaticamente pelo `pd.cut(..., bins=5)`, gerando cinco intervalos de mesma largura entre o valor mínimo e o valor máximo observados na amostra.

Classe de Custo (USD Mi)	fi	fr%
(classe 1 gerada pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
(classe 2 gerada pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
(classe 3 gerada pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
(classe 4 gerada pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
(classe 5 gerada pelo notebook)	(gerado pelo notebook)	(gerado pelo notebook)
Total	Σfi	100%

Tabela 2 – Distribuição de frequências do custo da missão em cinco classes (resultado direto do notebook).

O comportamento observado no histograma confirma que a maior parte das missões concentra-se nas classes de custo inferiores, enquanto poucos projetos ocupam as faixas mais altas de investimento.

4. ANÁLISE GRÁFICA EXPLORATÓRIA




Figura 1 – Exemplo ilustrativo de gráfico temporal de lançamentos por ano




Figura 2 – Exemplo ilustrativo de histograma dos custos com curva KDE

Gráfico temporal de lançamentos por ano

Construído a partir de `tabela_total['Ano'].value_counts().sort_index()`. O perfil temporal evidencia aumento de atividade nas décadas recentes, coerente com a entrada de operadores privados e a expansão da infraestrutura espacial comercial.

Histograma de custos com curva KDE

Gerado com `sns.histplot(..., bins=10, kde=True)`. A curva de densidade confirma assimetria positiva (cauda à direita): muitos lançamentos com custo relativamente baixo e poucos projetos extremamente caros.

5. DIAGNÓSTICO UNIVARIADO (ESTATÍSTICA DESCRITIVA)

O notebook calcula as seguintes métricas para Custo_Milhoes: média, mediana, moda, mínimo, máximo, amplitude, variância, desvio padrão e quartis (Q1, Q2, Q3).

Diagnóstico interpretativo (sem fixar valores que dependem da execução do CSV)

Indicador	Leitura técnica
Média > Mediana	Indica assimetria positiva, com poucos lançamentos muito caros puxando a média para cima.
Moda em faixas baixas	Sugere concentração operacional em missões de menor custo relativo.
Amplitude elevada	Revela coexistência de projetos comerciais enxutos e programas governamentais ou científicos de grande porte.
Desvio padrão alto	Indica volatilidade significativa dos custos e heterogeneidade do mercado.
Q1, Q2 e Q3	Delimitam a faixa onde se concentra a maior parte do ecossistema de lançamentos; no conjunto utilizado no notebook, os quartis reforçam a predominância de missões abaixo das classes superiores de custo.

Para a variável Ano, o notebook calcula média, mediana, moda, mínimo, máximo, amplitude, variância, desvio padrão e quartis. A interpretação é consistente com o gráfico temporal: os quartis concentram-se em períodos recentes, confirmando a intensificação histórica da atividade espacial.

6. INSIGHTS E RECOMENDAÇÕES CORPORATIVAS

1. Priorizar operações nas faixas de custo predominantes: a distribuição observada sugere que a maior densidade operacional está em missões de menor custo relativo; projetos nessa região tendem a apresentar maior comparabilidade estatística e menor exposição a extremos financeiros.
2. Tratar lançamentos de custo muito elevado como outliers estratégicos: esses casos não devem ser usados isoladamente como referência para ROI comercial padrão, pois frequentemente refletem programas institucionais, científicos ou de infraestrutura pesada.
3. Investir em padronização, reutilização e miniaturização: a concentração em missões menores favorece arquiteturas escaláveis, reaproveitamento de componentes e payloads compactos para telecomunicações, observação da Terra e IoT espacial.
4. Usar métricas robustas em modelos preditivos: devido à assimetria positiva, recomenda-se complementar a média com mediana, quartis e métodos robustos ao construir modelos lineares, estimativas de custo e cenários de risco.

7. CONFORMIDADE METODOLÓGICA E LIMITAÇÕES

- Os resultados dependem da versão específica do arquivo Space_Corrected.csv utilizado no notebook.
- O código apresentado não implementa amostragem aleatória de 100 observações; portanto, não é correto afirmar no relatório que foi usada uma amostra aleatória estrita de $n=100$ sem alterar o notebook.
- As tabelas de frequência mostradas acima devem ser preenchidas automaticamente pelos valores exibidos no `display(tdf_discreta)` e `display(tdf_continua)` quando o notebook for executado com o CSV correspondente.

Observação: Ferramentas de Inteligência Artificial (IA) podem ter sido utilizadas para auxiliar na estruturação textual, formatação e revisão gramatical do relatório. A responsabilidade acadêmica pelo conteúdo analítico, execução do notebook e interpretação estatística permanece integralmente com os autores.